

# Modélisation du prix d'un bien immobilier à Paris intramuros

Mais dis-moi chérie, le prix du m<sup>2</sup> a vachement augmenté !

Maxime PHILIPPOT

Pierre LEPAGNOL

2020-01-14

## Résumé

Nous avons voulu modéliser le prix d'un bien immobilier dans Paris. Pour pouvoir répondre à la question que beaucoup de monde se pose : "Pourquoi est-ce donc si cher ?". Ainsi pouvoir justifier un prix ou bien prédire pour des futurs biens pour dénicher les offres intéressantes à l'aide d'un algorithme reposant sur nos modèles. Pour ce faire nous avons du créer notre propre dataset en récoltant nos données sur différents sites web.

La seconde partie de notre travail fût la modélisation. Nous avons sélectionné nos variables de manière naïve, calculer le plus d'indicateurs (des distances, par exemple) qui soient indépendants les uns des autres. Puis en mettant en oeuvre notre cours d'Econométrie nous avons simulé avec nos données. Nous avons pu remarquer au long de l'étude que nous avons menée, la difficulté d'acquérir les données et parmi lesquelles : la position géographique des biens.

Un de nos premiers résultats fût la non corrélation avec le nombre de photos d'une annonce immobilière.

## Table des matières

<b>1</b>	<b>Création du dataset</b>	<b>2</b>
1.1	Récupération des Biens Immobiliers Bruts sous Python . . . . .	2
1.1.1	Problème et Résolution . . . . .	2
1.2	Création du data.frame <b>station</b> sous R . . . . .	3
1.2.1	Lecture du jeu de données et sélection . . . . .	3
1.2.2	Nettoyage du jeu de données . . . . .	3
1.3	Création du data.frame <b>biens</b> sous R . . . . .	4
1.3.1	Lecture du jeu de données et Sélection . . . . .	4
1.3.2	Prise en compte des stations sans référencement . . . . .	5
1.3.3	Ajout des coordonnées GPS des stations au data.frame <b>biens</b> . . . . .	7
1.3.4	Ajout de la distance des biens aux stations au data.frame <b>biens</b> . . . . .	8
1.3.5	Ajout de la distance des biens aux monuments les plus visités de Paris . . . . .	9
1.3.6	Ajout de la distance des biens à l'Université la plus proche au data.frame <b>biens</b> . . . . .	9
1.3.7	Transformation de la variable qualitative "type" . . . . .	10
1.3.8	Ajout d'une variable binaire sur les arrondissements . . . . .	10

<b>2</b>	<b>Statistique Descriptive</b>	<b>10</b>
2.0.1	Résumé statistique . . . . .	10
2.0.2	Statistique descriptive de la variables expliciter . . . . .	12
2.0.3	Distance des biens aux monuments . . . . .	13
2.0.4	Matrice de variance-covariance . . . . .	14
<b>3</b>	<b>Modèle Econométrique</b>	<b>18</b>
<b>4</b>	<b>Annexes</b>	<b>21</b>
4.1	Code Python . . . . .	21
	<b>Références</b>	<b>24</b>

## 1 Création du dataset

### 1.1 Récupération des Biens Immobiliers Bruts sous Python

#### 1.1.1 Problème et Résolution

Il n'y avait aucun jeu de donnée déjà formaté. Ainsi nous avons récupéré nos données en scrappant le site PAP<sup>1</sup>. Ce site présente l'avantage d'être un site d'annonces n'appartenant pas à une agence donc le prix affiché n'est pas surévalué d'une marge d'une agence. Nous nous sommes restreints aux biens en vente seule (pas de bien en viager, pas de bien location) et nous avons exclus les fonds de commerce, garage, péniche, chalet, mobil-homes, locaux en tout genre.

Nous avons ainsi 99 appartements, 4 maisons, 21 studios, 2 chambres et 3 pièces.

Nous avons récolté, pour chaque bien immobilier, le `type`, le `prix`, le nombre de photo (`nb_photo`), les trois transports les plus proches selon PAP (`transport_#`), le nombre de pièces (`nb_pieces`), le nombre de chambre (`nb_chambre`), la surface habitable (`surface`), le code postal (`code_postal`), la latitude `lat`, La longitude `lon`, l'url pour accéder à l'annonce (`url`).

Pour réaliser le scrapping nous avons utilisé les modules suivants :

- `requests` : Pour les requêtes HTTP.
- `unicodecode` : Pour la gestion des caractères spéciaux.
- `datetime` : Pour dater nos fichiers.
- `ast` : Pour parser une chaîne de caractère en dictionnaire Python.
- `json` : Pour gérer les fichiers json
- `re` : Pour la gestion des expression.
- `bs4` (BeautifulSoup) : Pour scrapper les pages web.

Pour accéder aux données nous avons effectué une requête HTTP à l'adresse :

<https://www.pap.fr/annonce/vente-immobiliere-paris-75-g439>

Nous avons réparti le code en plusieurs fonctions:

---

1. (« PAP: Particulier à Particulier » 2020)

```

# Initiation de la racine du site web
site_main='https://www.pap.fr'

# Création d'un set() contenant toutes les urls des biens
URLset=GetURLSET(site_main,20)
# Nettoyage du set() pour enlever les types de biens "intéressants"
# (Fond de commerces, locaux, péniches, etc).
URLset=CleanIDset(URLset)

#Création du jeu de données brut
data=GetDetails(site_main,URLset)

#Exportation de l'objet data (dict) dans un fichier .json
exportdata(data)

```

Vous trouverez en annexe, le code complet.

## 1.2 Création du dataframe station sous R

### 1.2.1 Lecture du jeu de données et sélection

Le fichier “positions-geographiques-des-stations-du-reseau-ratp.csv” provient du jeu de données de la RATP <sup>2</sup>. Ce fichier contient les coordonnées GPS et l’adresse des stations de bus, métro, RER, Tramway de la RATP.

Vous trouverez à Références l’adresse pour télécharger le jeu de donnée.

```

station<-read.csv("../Ddatasets/positions-geographiques-des-stations-du-reseau-ratp.csv",header= T,sep
# Ajout du code postal au data.frame et ordonner par code_postal

station<-cbind(station,code_postal=str_sub(as.character(station[,3]),-5))
station<-station[order(station$code_postal),]
station$code_postal<-as.numeric(as.character(station$code_postal))

# Mise en forme UTF-8 pour rectifier l'erreur d'écriture des stations avec des accents (les stations de

fwrite(station,"../Ddatasets/station_UTF-8.csv")
station <- fread("../Ddatasets/station_UTF-8.csv",encoding = "UTF-8")

# Séparation de Longitude et Latitude en deux colonnes

setDT(station)[, c("Latitude","Longitude") := tstrsplit(Coordinates, ",")]

#Sélection uniquement des stations de Paris et ordonner par nom de station

station<- station[station$code_postal < 75121,]
station<-station[order(station$Name),]

```

### 1.2.2 Nettoyage du jeu de données

On a remarqué que certaines stations avaient des adresses identiques, on a donc comparé les données Longitude/Latitude. Ces données ce sont avérées redondantes également. On a décidé de supprimer les

---

2. (« RATP Open Data » 2020)

stations qui possédaient plusieurs points GPS identique pour une même adresse, autrement dit une adresse est maintenant associée à un point GPS unique.

```
# Suppression des doublons Longitude/Latitude dans le data.frame
```

```
station<-station[!duplicated(station[,c(3,6:7)]),]
```

Notre jeu de données qui provient de la RATP n'écrit pas de la même façon une station de métro et une station de bus. "Alésia" est une station de métro. "ALESIA - DIDOT" est un arrêt de bus. Pour uniformiser le nom des stations il faut donc supprimer les accents, puis toutes les mettre en majuscule.

```
# Supprime les accents des stations de métro de notre jeu de données
```

```
for (i in seq(1, length(station$Name))){  
  station$Name[i]<-iconv(station$Name[i],from="UTF-8",to="ASCII//TRANSLIT")  
}
```

```
# Mise en forme de toutes les stations (en majuscule)
```

```
station$Name<-str_to_upper(station$Name)
```

On a supprimé également les lignes pour lesquelles les adresses étaient identiques pour ne garder qu'un point GPS par adresse.

On a remarqué qu'une station de métro pouvait avoir des données identiques d'adresse mais un point GPS différent. Une explication serait que les bouches de métro sont référencées et donc pour une station de métro et une adresse nous obtenons plusieurs points GPS différents (ce n'est qu'une hypothèse). On a décidé de garder qu'une information par station de métro.

```
# Sélection d'une coordonnées GPS par adresse.
```

```
station<-station[!duplicated(station[,3]),]
```

```
station<-station[, -4] #on enlève "Coordinates" qui est maintenant en deux colonnes "Longitude" et "Latitude"
```

```
# On garde une ligne par station de métro en faisant la moyenne de Longitude/Latitude lorsqu'il y en a plusieurs
```

```
station<-station%>%
```

```
  group_by(Name)%>%summarise(longitude=mean(as.numeric(Longitude)),latitude=mean(as.numeric(Latitude)))
```

## 1.3 Création du data.frame biens sous R

### 1.3.1 Lecture du jeu de données et Sélection

le fichier "result\_python\_annonces.csv" provient du scrapping des annonces effectué à l'aide de Python. Pour chaque bien (ou presque), nous avons de l'informations sur trois stations à proximité (métro,RER)

```
biens<-read.csv("../Datasets/result_python_annonces.csv",header= T,sep=",")
```

```
# Mise en forme UTF-8 pour rectifier l'erreur d'écriture des stations avec des accents
```

```
fwrite(biens,"../Datasets/biens_UTF-8.csv")
```

```
biens <- fread("../Datasets/biens_UTF-8.csv",encoding = "UTF-8")
```

```

# Supprime les accents des stations de chaque biens pour uniformiser avec la même écriture que le data.

for (i in seq(1, length(biens$transport.0))){
  biens$transport.0[i]<-iconv(biens$transport.0[i],from="UTF-8",to="ASCII//TRANSLIT")
  biens$transport.1[i]<-iconv(biens$transport.1[i],from="UTF-8",to="ASCII//TRANSLIT")
  biens$transport.2[i]<-iconv(biens$transport.2[i],from="UTF-8",to="ASCII//TRANSLIT")
}

# Mise en forme de toutes les stations (en majuscule)

biens$transport.0<-str_to_upper(biens$transport.0)
biens$transport.1<-str_to_upper(biens$transport.1)
biens$transport.2<-str_to_upper(biens$transport.2)

# Donne l'ensemble des stations présentes dans le jeu de données ``biens``

transport<-unique(c(biens$transport.0,biens$transport.1,biens$transport.2))

# On ordonne par le nom de la première station renseignée, puis on a décidé de supprimer les biens pour

biens<-biens[order(biens$transport.0),]
biens<-biens[-c(1,2,3,4,5),]

```

On a remarqué un bien sans description du nombre de chambre. A l'aide de l'url renseigné dans le data.frame nous avons visité la page <https://www.pap.fr/annonces/appartement-paris-16e-75016-r430400259> correspondant au bien.

Si on regarde la photo du plan sur l'annonce on remarque que le bien peut avoir 1 ou 2 chambres selon les besoins/envies de l'acheteur, on a décidé que ce bien possédais qu'une chambre à l'achat et que la salle à manger pouvait se transformer en chambre par la suite.

*#url du bien*

```
subset(biens,is.na(biens$nb_chambres))$url
```

```
## [1] "/annonces/appartement-paris-16e-75016-r430400259"
```

*# On associe 1 chambre à ce bien*

```
biens$nb_chambres[is.na(biens$nb_chambres)]<-1
```

### 1.3.2 Prise en compte des stations sans référencement

Nous avons vu très rapidement que certaines stations référencées dans l'annonce ne correspondaient à aucune station du data.frame "station".

```

# On cherche donc les stations du data.frame ``biens`` qui n'ont pas de valeurs dans le data.frame "s
sort(setdiff(transport,unique(station$Name)))#on a 30 stations sur 198 qui n'ont pas de correspondance

```

```
## [1] ""
## [2] "ALEXANDRE DUMAS"
## [3] "AVENUE HENRI MARTIN"
## [4] "BUTTES CHAUMONT"
## [5] "CHAMPS-ELYSEES - CLEMENCEAU (GRAND PALAIS)"
## [6] "CHATEAU-LANDON"
## [7] "CHATELET - LES HALLES"
## [8] "CLUNY - LA SORBONNE"
## [9] "CORENTIN CARIOU"
## [10] "FRANKLIN D. ROOSEVELT"
## [11] "GONCOURT (HOPITAL-SAINT-LOUIS)"
## [12] "HOPITAL ROBERT-DEBRE"
## [13] "JAVEL - ANDRE CITROEN"
## [14] "LA MOTTE-PICQUET - GRENELLE"
## [15] "MAGENTA"
## [16] "MARX DORMOY"
## [17] "NEUILLY - PORTE MAILLOT"
## [18] "NOTRE-DAME-DE-LORETTE"
## [19] "PEREIRE - LEVALLOIS"
## [20] "PEREIRE (MARECHAL JUIN)"
## [21] "PLACE MONGE (JARDIN DES PLANTES - ARENES DE LUTECE)"
## [22] "PONT DE L'ALMA"
## [23] "PONT-CARDINET"
## [24] "PORTE DE PANTIN (PARC DE LA VILLETTE)"
## [25] "PORTE DE SAINT-CLOUD (PARC DES PRINCES)"
## [26] "PORTE DE VERSAILLES (PARC DES EXPOSITIONS DE PARIS)"
## [27] "PORTE MAILLOT (PALAIS DES CONGRES)"
## [28] "SAINT-SEBASTIEN - FROISSART"
## [29] "SOLFERINO (MUSEE D'ORSAY)"
## [30] "STADE CHARLETY"
## [31] "TELEGRAPHE"
```

```
#length(transport) #transport qui est l'ensemble des stations référencées dans les 124 biens
```

Pour corriger ce problème, nous avons créé le fichier `result_r_station.csv` pour connaître le nom de toutes les stations de Paris ordonnées. On a associé manuellement les nouveaux noms de station en mettant en évidence deux causes de ce problème.

La première cause venait d’une écriture différente dans les deux data.frame. Par exemple, “JAVEL - ANDRE CITROEN” est devenu “JAVEL-ANDRE-CITROEN”, “FRANKLIN D. ROOSEVELT” est devenu “FRANKLIN-ROOSEVELT” etc...

Ensuite, dans l’autre cas la cause venait d’un manque d’information sur les stations RER du jeu de données de la RATP. On a décidé d’associer la station de bus la plus proche de la station de RER pour garder une bonne information. Par exemple, “PONT DE L’ALMA” est devenu “BOSQUET - RAPP”, “TELEGRAPHE” est devenu “PELLEPORT - BELLEVILLE”, “STADE CHARLETY” est devenu “STADE CHARLETY - PORTE DE GENTILLY” etc...

```
# Création du fichier des stations pour trouver le nom exact des stations de métro, ou dans l'autre cas
```

```
#write.csv(station, file = "result_r_station.csv")
```

```
biens[biens=="ALEXANDRE DUMAS"]<-"ALEXANDRE-DUMAS"
biens[biens=="AVENUE HENRI MARTIN"]<-"OCTAVE FEUILLET"
```

```

biens[biens=="BUTTES CHAUMONT"]<-"BUTTES-CHAUMONT"
biens[biens=="CHAMPS-ELYSEES - CLEMENCEAU (GRAND PALAIS)"]<-"CHAMPS-ELYSEES - CLEMENCEAU"
biens[biens=="CHATEAU-LONDON"]<-"CHATEAU LONDON"
biens[biens=="CHATELET - LES HALLES"]<-"CHATELET-LES HALLES"
biens[biens=="CLUNY - LA SORBONNE"]<-"CLUNY-LA SORBONNE"
biens[biens=="CORENTIN CARIOU"]<-"CORENTIN-CARIOU"
biens[biens=="FRANKLIN D. ROOSEVELT"]<-"FRANKLIN-ROOSEVELT"
biens[biens=="GONCOURT (HOPITAL-SAINT-LOUIS)"]<-"GONCOURT (HOPITAL SAINT-LOUIS)"
biens[biens=="HOPITAL ROBERT-DEBRE"]<-"HOPITAL ROBERT DEBRE"
biens[biens=="JAVEL - ANDRE CITROEN"]<-"JAVEL-ANDRE-CITROEN"
biens[biens=="LA MOTTE-PICQUET - GRENELLE"]<-"LA MOTTE-PICQUET-GRENELLE"
biens[biens=="MAGENTA"]<-"LA FAYETTE - DUNKERQUE"
biens[biens=="MARX DORMOY"]<-"MARX-DORMOY"
biens[biens=="NEUILLY - PORTE MAILLOT"]<-"PORTE MAILLOT - PALAIS DES CONGRES"
biens[biens=="NOTRE-DAME-DE-LORETTE"]<-"NOTRE-DAME DE LORETTE"
biens[biens=="PEREIRE - LEVALLOIS"]<-"PEREIRE"
biens[biens=="PEREIRE (MARECHAL JUIN)"]<-"PEREIRE - MARECHAL JUIN"
biens[biens=="PLACE MONGE (JARDIN DES PLANTES - ARENES DE LUTECE)"]<-"PLACE MONGE (JARDIN DES PLANTES)"
biens[biens=="PONT-CARDINET"]<-"PONT CARDINET"
biens[biens=="PONT DE L'ALMA"]<-"BOSQUET - RAPP"
biens[biens=="PORTE DE PANTIN (PARC DE LA VILLETTE)"]<-"PORTE DE PANTIN - PARC DE LA VILLETTE"
biens[biens=="PORTE DE SAINT-CLOUD (PARC DES PRINCES)"]<-"PORTE DE SAINT-CLOUD"
biens[biens=="PORTE DE VERSAILLES (PARC DES EXPOSITIONS DE PARIS)"]<-"PORTE DE VERSAILLES - PARC DES EX"
biens[biens=="PORTE MAILLOT (PALAIS DES CONGRES)"]<-"PORTE MAILLOT - PALAIS DES CONGRES"
biens[biens=="SAINT-SEBASTIEN - FROISSART"]<-"SAINT-SEBASTIEN-FROISSART"
biens[biens=="SOLFERINO (MUSEE D'ORSAY)"]<-"SOLFERINO - BELLECHASSE"
biens[biens=="STADE CHARLETY"]<-"STADE CHARLETY - PORTE DE GENTILLY"
biens[biens=="TELEGRAPHE"]<-"PELLEPORT - BELLEVILLE"

transport<-unique(c(biens$transport.0,biens$transport.1,biens$transport.2))
sort(setdiff(transport,unique(station$Name)))

```

```
## character(0)
```

On remarque bien que maintenant toutes les stations référencées dans les annonces possèdent une association dans le data.frame `station`

### 1.3.3 Ajout des coordonnées GPS des stations au data.frame biens

On peut commencer par associer à chaque bien les coordonnées des stations les plus proches. Par exemple, `Latitude_transport.0` est la latitude de la première station de métro/RER référencée dans l'annonce, `Longitude_transport.1` est la longitude de la deuxième station de métro/RER référencée dans l'annonce, etc...

```

# On intègre les coordonnées GPS des stations de l'annonce à notre data.frame ``biens``

colnames(station)[1]<-"transport.0"
transport0<-merge(biens,station, by="transport.0")
transport0<-transport0[order(transport0$transport.0),]

colnames(station)[1]<-"transport.1"
transport1<-merge(biens,station, by="transport.1")

```

```

transport1<-transport1[order(transport1$transport.0),]

colnames(station)[1]<-"transport.2"
transport2<-merge(biens,station, by="transport.2")
transport2<-transport2[order(transport2$transport.0),]

biens<-biens[order(biens$transport.0),]
biens<-cbind(biens,Latitude_transport.0=transport0$latitude,Longitude_transport.0=transport0$longitude,

```

### 1.3.4 Ajout de la distance des biens aux stations au data.frame biens

On a décidé de calculer la distance du bien aux stations de métro/RER pour déterminer si le fait que les stations de métro/RER soit éloignées ou proches a une incidence sur le prix. On peut déjà émettre l'hypothèse que cette distance ne devrait pas influer sur le prix puisqu'il existe énormément de station de métro/RER à Paris. Par conséquent, pour chaque bien il va forcément y avoir une station proche.

Cela sera à prouver lors de notre modélisation lorsqu'on décidera ou non de garder ces variables dans notre modèle final.

*#On intègre les distances des biens aux stations de métro/RER référencées dans l'annonce*

```

dist_metro0=c()
dist_metro1=c()
dist_metro2=c()

for (i in seq(1, length(biens$code.postal))){
  dist_metro0=c(dist_metro0,distHaversine(c(biens$lon[i],biens$lat[i]),c(biens$Longitude_transport.0[
}

distHaversine(c(2.270395,48.86509),c(2.269568,48.86309))

```

```
## [1] 230.7291
```

```

for (i in seq(1, length(biens$code.postal))){
  dist_metro1=c(dist_metro1,distHaversine(c(biens$lon[i],biens$lat[i]),c(biens$Longitude_transport.1[
}

for (i in seq(1, length(biens$code.postal))){
  dist_metro2=c(dist_metro2,distHaversine(c(biens$lon[i],biens$lat[i]),c(biens$Longitude_transport.2[
}

dist_metro<-data.frame(dist_metro0,dist_metro1,dist_metro2)
colnames(dist_metro)<-c("distance_station_0","distance_station_1","distance_station_2")

biens<- cbind(biens,dist_metro)

```



### 1.3.5 Ajout de la distance des biens aux monuments les plus visités de Paris

On enrichit le data.frame `biens` à l'aide des coordonnées GPS<sup>3</sup> des monuments de Paris<sup>4</sup> récoltées sur internet.

Pour obtenir ces données il suffit de se rendre à l'adresse en Références et de rentrer le nom du monument pour obtenir la longitude et latitude.

```
# On calcule la distance des biens à ces 11 monuments.

monument<-read.csv("../Datasets/monuments_paris.csv",header= T,sep=",",encoding = "UTF-8")

mon=c()
dist_monu=data.frame()
for (i in seq(1, length(biens$code.postal))){
  mon=c()
  for (c in seq(1, length(monument$Nom))){

    mon=c(mon,distHaversine(c(biens$lon[i],biens$lat[i]), c(monument$Longitude[c],monument$Latitude[c]))
  }
  dist_monu<-rbind(dist_monu,mon)
}
colnames(dist_monu)<-monument$Nom

biens<- cbind(biens,dist_monu)
```

### 1.3.6 Ajout de la distance des biens à l'Université la plus proche au data.frame biens

On enrichit le data.frame `biens` à l'aide des coordonnées GPS des principales universités de Paris<sup>5</sup> récoltées sur internet.

Pour obtenir ces données, il faut appliquer la même procédure que pour les monuments.

Dans ce cas, on ne calcule pas la distance des biens à toutes les universités mais la distance du biens à l'université la plus proche. On ajoute donc une seule colonne au data.frame

```
# Lecture du fichier
universite<-read.csv("../Datasets/université_paris.csv",header= T,sep=",",encoding = "UTF-8")

# Calcule de la distance du bien pour chaque université puis sélection du minimum pour garder la distan
dist_uni=rep(0,124)
for (i in seq(1, length(biens$code.postal))){
  v=rep(0,7)
  for (c in seq(1, length(universite$Nom))){

    v[c]=distHaversine(c(biens$lon[i],biens$lat[i]), c(universite$Longitude[c],universite$Latitude[c]),
  }
  dist_uni[i]=min(v)
}

biens<-cbind(biens,distance_université_plus_près=dist_uni)
```

---

3. (« Coordonnées GPS » 2020)

4. (« Monuments de Paris » 2020)

5. (« Université de Paris » 2020)

### 1.3.7 Transformation de la variable qualitative “type”

On a une variable qualitative qui donne le type de bien de l’annonce: appartement,maison,chambre,pièce,studio.

*#On considère que les types "pièce" et "chambre" reflètent la même information, on associe "pièce" à "c*

```
biens[biens=="pièce"]<-"chambre"
```

*#On rajoute quatres colonnes à gauche pour mettre la variable "type" qui est qualitative en 4 variable*

```
app=c()
stu=c()
mai=c()
cha=c()
for (i in seq(1, length(biens$code.postal))){
  if(biens$type[i]=="appartement") {app=c(app,1)} else {app=c(app,0)}
  if(biens$type[i]=="studio") {stu=c(stu,1)} else {stu=c(stu,0)}
  if(biens$type[i]=="maison") {mai=c(mai,1)} else {mai=c(mai,0)}
  if(biens$type[i]=="chambre") {cha=c(cha,1)} else {cha=c(cha,0)}
}
biens<-cbind(appartement=app,studio=stu,maison=mai,chambre=cha,biens)
```

### 1.3.8 Ajout d’une variable binaire sur les arrondissements

On a choisit de retranscrire en variable binaire le fait que le bien est soit dans la première corone de Paris (arrondissement de 1 à 11) ou dans la deuxième couronne (arrondissement de 12 à 20).

*#On choisit de mettre 0 lorsque le bien est dans l'hyper-centre et 1 sinon (i.e. 0 du 1er au onzième ar*

```
arr=c()
for (i in seq(1, length(biens$code.postal))){
  if(as.numeric(str_sub(biens$code.postal[i],-2))<12) {arr=c(arr,0)} else {arr=c(arr,1)}
}
biens<-cbind(biens,arrondissement=arr)
```

## 2 Statistique Descriptive

Dans cette partie, on a étudié les variables explicatives que l’on trouvait les plus judicieuses à analyser. Notre jeu de données “biens” possède une multitude de valeurs inutiles à analyser (lat,lon,type,transport.0,Longitude\_transport.2...). On a dans un premier temps réduit ce jeu de données aux variables intéressantes.

### 2.0.1 Résumé statistique

A l’aide de ce résumé on peut analyser nos différentes variables avant d’en faire un modèle. On remarque beaucoup d’appartement et studio dans notre jeu de données, ils représentent presque 90% de nos biens. On constate que 50% des annonces ont moins de 10 photos avec certaines annonces sans photos.

Le prix des biens, le nombre de pièces, le nombre de pièces et la surface vont être analysés plus en détails.

Si on regarde les distances aux stations on remarque qu'en moyenne les stations sont rangées dans l'ordre dans les annonces. Autrement dit, la station la plus proche est nommer en premier dans l'annonce, suivi de la deuxième station la plus proche pour finir par la troisième station de métro/RER la plus proche. A noter que la distance Haversine est exprimée en mètres et prend en compte l'ellipsoïde de la Terre. Cela n'a pas vraiment d'incidence dans notre cas puisque les distances sont relativement proche. Pour les distances des biens aux monuments par exemple cela varie de simplement quelques mètres lorsqu'on prend en compte ou non la sphère de la Terre. On remarque qu'en moyenne la première station renseignée est à 228.03m du bien. 25% des biens ont la première station à moins de 152.25m. On constate également une répartition plutôt équitablement répartie avec 50% des biens ayant la première station à moins de 229.32m et 50% des autres ayant une station comprise entre 229.32m et 539.63m. Pour ce qui est de la deuxième et troisième station on obtient également des répartitions équitables puisqu'on a 50% des biens à moins de 387.49m de la station (maximum à 869.20m) dans le premier cas, et 50% des biens à moins de 490.3m de la station (maximum à 1138.5m) dans le second cas. On peut ainsi confirmer que le nombre important de stations de métros/RER dans Paris rend des distances faibles puisque pratiquement tous les biens ont une station de métro/RER à moins de 1km.

Si on regarde les distances des biens aux monuments les plus visités de Paris on remarque qu'en moyenne tous nos biens sont plus proches du Musée du Louvre, ils sont en moyenne à 3415.7m.

```
# Comparaison de deux distances avec et sans prise en compte de la sphère de la Terre

#distHaversine(c(biens$lon[1],biens$lat[1]), c(monument$Longitude[1],monument$Latitude[1]), r=6378137)
#distGeo(c(biens$lon[1],biens$lat[1]), c(monument$Longitude[1],monument$Latitude[1]))

# Sélection des variables

biens_stat_des<-biens[,c(1,2,3,4,6,7,12,13,14,24,25,26,27,28,29,30,31,32,33,34,35,36,37,38,39)]

#Transformation des variables qualitatives en facteur de niveaux

biens_stat_des$appartement<-as.factor(biens_stat_des$appartement)
biens_stat_des$studio<-as.factor(biens_stat_des$studio)
biens_stat_des$maison<-as.factor(biens_stat_des$maison)
biens_stat_des$chambre<-as.factor(biens_stat_des$chambre)
biens_stat_des$arrondissement<-as.factor(biens_stat_des$arrondissement)

summary(biens_stat_des)
```

```
## appartement studio maison chambre nb_photo prix
## 0:30 0:103 0:120 0:119 Min. : 0.000 Min. : 91000
## 1:94 1: 21 1: 4 1: 5 1st Qu.: 6.000 1st Qu.: 388750
## Median :10.000 Median : 650000
## Mean : 8.935 Mean : 728296
## 3rd Qu.:12.000 3rd Qu.: 926250
## Max. :18.000 Max. :4113500
## nb_pieces nb_chambres surface distance_station_0
## Min. : 1.000 Min. :0.000 Min. : 7.00 Min. : 14.37
## 1st Qu.: 2.000 1st Qu.:1.000 1st Qu.: 35.00 1st Qu.:152.25
## Median : 3.000 Median :1.000 Median : 56.50 Median :229.32
## Mean : 2.726 Mean :1.532 Mean : 59.98 Mean :228.03
## 3rd Qu.: 3.250 3rd Qu.:2.000 3rd Qu.: 84.00 3rd Qu.:278.32
## Max. :11.000 Max. :8.000 Max. :252.00 Max. :539.63
## distance_station_1 distance_station_2 Cathédrale Notre-Dame de Paris
## Min. : 70.54 Min. : 248.3 Min. : 489.1
```


```
## 1st Qu.:315.16      1st Qu.: 403.4      1st Qu.:2565.8
## Median :387.49      Median : 490.3      Median :3720.9
## Mean   :415.35      Mean   : 534.9      Mean   :3623.1
## 3rd Qu.:510.29      3rd Qu.: 635.5      3rd Qu.:4644.3
## Max.   :869.20      Max.   :1138.5      Max.   :6951.4
## Basilique du Sacré-Cœur de Montmartre Musée du Louvre Tour Eiffel
## Min.    : 403.4                      Min.    : 458.5 Min.    : 460.5
## 1st Qu.:2355.5                      1st Qu.:2543.3 1st Qu.:2439.6
## Median :4324.0                      Median :3489.6 Median :4101.6
## Mean   :4168.5                      Mean   :3415.7 Mean   :4325.9
## 3rd Qu.:5943.1                      3rd Qu.:4274.6 3rd Qu.:5953.8
## Max.   :8224.4                      Max.   :6394.3 Max.   :8596.4
## Centre Pompidou Musée d'Orsay Cité des sciences et de l'industrie
## Min.    : 615.3 Min.    : 490.3 Min.    : 803.3
## 1st Qu.:2329.2 1st Qu.:2623.7 1st Qu.: 4126.9
## Median :3668.3 Median :3383.7 Median : 5854.1
## Mean   :3520.1 Mean   :3495.0 Mean   : 5991.3
## 3rd Qu.:4320.4 3rd Qu.:4326.2 3rd Qu.: 7890.6
## Max.   :7360.5 Max.   :6339.9 Max.   :11458.3
## Chapelle Notre-Dame de la Médaille miraculeuse
## Min.    : 562.3
## 1st Qu.:2697.2
## Median :3775.5
## Mean   :3699.0
## 3rd Qu.:4519.3
## Max.   :6787.9
## Grand site du Jardin des plantes Arc de triomphe Grand Palais
## Min.    : 92.22                      Min.    : 542.7 Min.    : 268.1
## 1st Qu.:2645.93                      1st Qu.:3146.8 1st Qu.:2461.0
## Median :3946.69                      Median :4217.3 Median :3602.9
## Mean   :3875.11                      Mean   :4466.5 Mean   :3754.1
## 3rd Qu.:5110.92                      3rd Qu.:6302.6 3rd Qu.:4963.6
## Max.   :7044.63                      Max.   :9105.0 Max.   :7594.0
## distance_université_plus_près arrondissement
## Min.    : 322.8                      0:41
## 1st Qu.:1758.2                      1:83
## Median :2433.0
## Mean   :2589.6
## 3rd Qu.:3391.3
## Max.   :5324.7
```

## 2.0.2 Statistique descriptive de la variables expliquer

On remarque que bon nombre de biens en un prix inférieur à 1 million d'euros. On a tout de même deux maisons a plus de 3 millions d'euros.

```
# Répartition du prix de l'ensemble des biens de notre jeu de données
```


```
prix_biens <- ggplot(biens_stat_des, aes(x = prix)) +
  geom_histogram(aes(y = ..count..), binwidth = 100000) +
  scale_x_continuous(breaks=seq(0,4500000,250000))+theme(axis.text.x = element_text(angle=90, size=12))
prix_biens
```



### 2.0.3 Distance des biens aux monuments

```
par(xaxt="n")
boxplot(biens_stat_des$`Cathédrale Notre-Dame de Paris`,biens_stat_des$`Basilique du Sacré-Cœur de Montparnasse`)

lablist<-colnames(biens_stat_des[,c(13,14,15,16,17,18,19,20,21,22,23)])
axis(1, at=seq(1, 11, by=1), labels = FALSE,las=2)
text(seq(1, 11, by=1), par("usr")[3] - 0.2, labels = lablist,adj= 1.1, srt = 45, xpd = TRUE,cex=0.5)
```



## 2.0.4 Matrice de variance-covariance

La matrice de variance-covariance nous sert à sélectionner dans notre modèle final que les variables indépendantes entre-elles. Sans surprise, on remarque que la surface d'un bien est fortement corrélée avec le nombre de pièces et le nombre de chambre. À l'aide de cette matrice nous remarquons également que les monuments proches sont fortement corrélés entre eux. Par exemple, le centre Pompidou et Cathédrale Notre-Dame de Paris ont une covariance de 0.94. Lorsqu'on sélectionnera le modèle final il faudra s'assurer que nous avons pas garder des monuments proches pour avoir des variables décorréliées entre elles.

```
mat_cor <- round(cor(biens[,c(6,12,13,14,24,25,26,27,28,29,30,31,32,33,34,35,36,37,38)]),2)
rownames(mat_cor) <- colnames(biens[,c(6,12,13,14,24,25,26,27,28,29,30,31,32,33,34,35,36,37,38)])

colnames(mat_cor) <-colnames(biens[,c(6,12,13,14,24,25,26,27,28,29,30,31,32,33,34,35,36,37,38)])

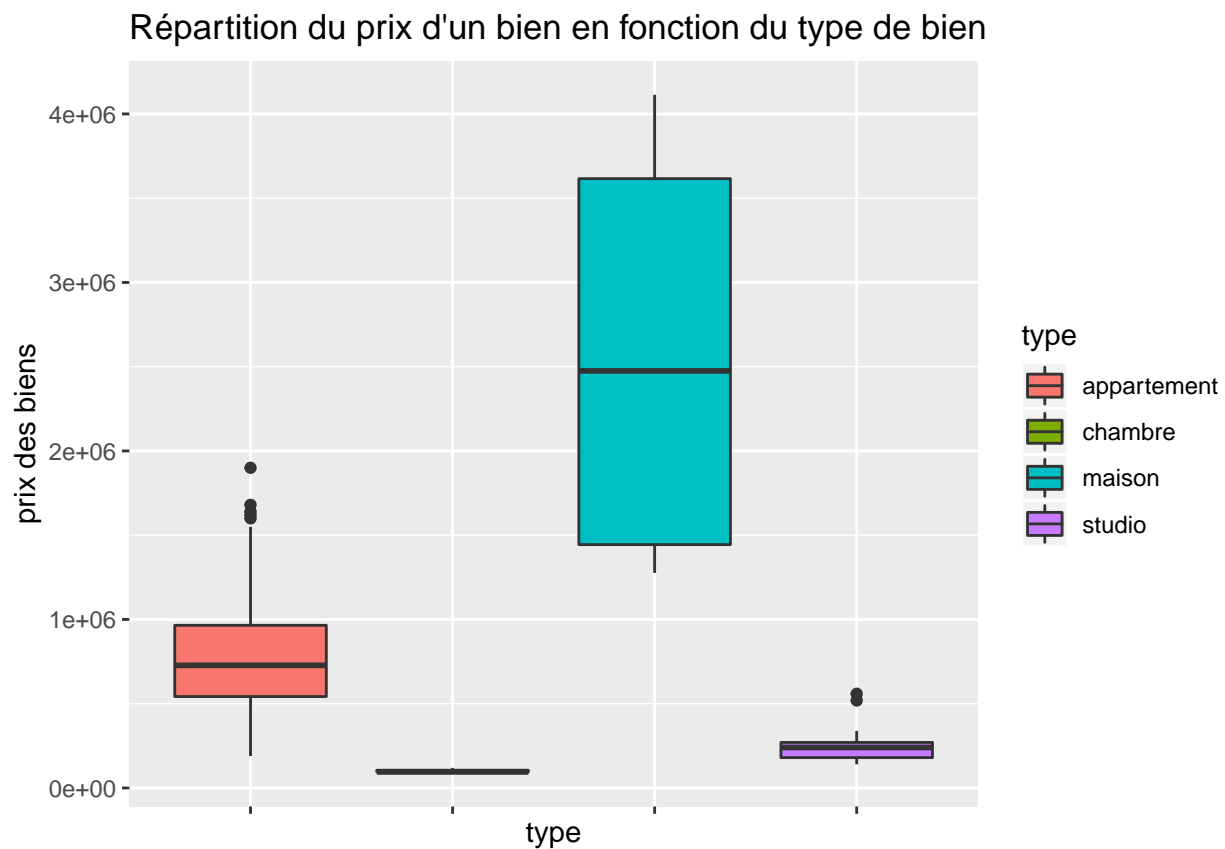
mat_cor<-data.frame(mat_cor)
head(mat_cor)
```

```
##          nb_photo nb_pieces nb_chambres surface distance_station_0
## nb_photo          1.00      0.21      0.23      0.22              0.05
## nb_pieces          0.21      1.00      0.94      0.91              0.15
## nb_chambres         0.23      0.94      1.00      0.84              0.17
## surface            0.22      0.91      0.84      1.00              0.09
## distance_station_0  0.05      0.15      0.17      0.09              1.00
## distance_station_1  0.08      0.24      0.26      0.21              0.31
##
##          distance_station_1 distance_station_2
## nb_photo          0.08          0.01
## nb_pieces          0.24         -0.05
## nb_chambres        0.26         -0.03
## surface            0.21         -0.05
```

## distance_station_0	0.31	0.25
## distance_station_1	1.00	0.35
## Cathédrale.Notre.Dame.de.Paris		
## nb_photo	0.12	
## nb_pieces	0.18	
## nb_chambres	0.23	
## surface	0.17	
## distance_station_0	0.10	
## distance_station_1	0.18	
## Basilique.du.Sacré.Cœur.de.Montmartre Musée.du.Louvre		
## nb_photo	0.08	0.11
## nb_pieces	0.29	0.27
## nb_chambres	0.32	0.32
## surface	0.25	0.20
## distance_station_0	0.12	0.14
## distance_station_1	0.12	0.26
## Tour.Eiffel Centre.Pompidou Musée.d.Orsay		
## nb_photo	-0.02	0.12
## nb_pieces	0.10	0.23
## nb_chambres	0.10	0.28
## surface	-0.01	0.22
## distance_station_0	0.03	0.13
## distance_station_1	0.11	0.18
## Cité.des.sciences.et.de.l.industrie		
## nb_photo	0.06	
## nb_pieces	0.16	
## nb_chambres	0.18	
## surface	0.20	
## distance_station_0	0.08	
## distance_station_1	0.02	
## Chapelle.Notre.Dame.de.la.Médaille.miraculeuse		
## nb_photo	0.04	
## nb_pieces	0.13	
## nb_chambres	0.16	
## surface	0.05	
## distance_station_0	0.04	
## distance_station_1	0.20	
## Grand.site.du.Jardin.des.plantes Arc.de.triomphe		
## nb_photo	0.11	0.00
## nb_pieces	0.11	0.18
## nb_chambres	0.14	0.20
## surface	0.12	0.05
## distance_station_0	0.06	0.06
## distance_station_1	0.13	0.14
## Grand.Palais distance_université_plus_près		
## nb_photo	0.03	0.01
## nb_pieces	0.21	0.03
## nb_chambres	0.24	0.05
## surface	0.08	-0.09
## distance_station_0	0.09	0.05
## distance_station_1	0.20	0.04

*#Répartition de tous les types de biens*

```
rep_biens <- ggplot(data=biens, aes(x=type, y=prix,fill=type))
rep_biens <- rep_biens +ggtitle("Répartition du prix d'un bien en fonction du type de bien")+ geom_boxp
rep_biens
```




```
# On élimine les maisons pour voir plus en détails la répartition des autres type de biens
biens_sans_mai<-biens[order(biens$type),][-c(100,101,102,103),]

# On obtient une nouvelle représentation
rep_biens_sans_mai <- ggplot(data=biens_sans_mai, aes(x=type, y=prix,fill=type))
rep_biens_sans_mai<- rep_biens_sans_mai +ggtitle("Répartition du prix d'un bien en fonction du type de l
rep_biens_sans_mai
```




## Répartition du prix d'un bien en fonction du type de bien (sans maison)



*# régression du prix des biens en fonction*

```
ggplot(biens,aes(x=surface,y=prix,color=type, shape=type))+geom_point()+scale_y_continuous(name="prix d
```

Evolution du prix du bien en fonction de la surface pour chaque type de b



### 3 Modèle Econométrique

*# On crée un premier modèle avec toutes les variables explicatives*

```
summary(lm(formula=biens$prix~biens$nb_chambres+biens$nb_photo+biens$surface+biens$nb_pieces+biens$dist
```

```
##
```

```
## Call:
```

```
## lm(formula = biens$prix ~ biens$nb_chambres + biens$nb_photo +
##     biens$surface + biens$nb_pieces + biens$distance_station_0 +
##     biens$distance_station_1 + biens$distance_station_2 + biens$`Cathédrale Notre-Dame de Paris` +
##     biens$`Basilique du Sacré-Cœur de Montmartre` + biens$`Musée du Louvre` +
##     biens$`Tour Eiffel` + biens$`Centre Pompidou` + biens$`Musée d'Orsay` +
##     biens$`Cité des sciences et de l'industrie` + biens$`Chapelle Notre-Dame de la Médaille miraculeuse` +
##     biens$`Grand site du Jardin des plantes` + biens$`Arc de triomphe` +
##     biens$`Grand Palais` + biens$distance_université_plus_près +
##     biens$appartement + biens$studio + biens$chambre + biens$arrondissement)
```

```
##
```

```
## Residuals:
```

```
##      Min       1Q   Median       3Q      Max
## -597981 -56713      216   60918  709974
```

```
##
```

```
## Coefficients:
```

```
##
```

Estimate Std. Error

```

## (Intercept) 3.593e+05 2.916e+05
## biens$nb_chambres 3.930e+04 4.561e+04
## biens$nb_photo 2.352e+03 4.250e+03
## biens$surface 1.394e+04 1.164e+03
## biens$nb_pieces -7.815e+04 4.668e+04
## biens$distance_station_0 1.235e+01 1.511e+02
## biens$distance_station_1 -1.640e+01 1.277e+02
## biens$distance_station_2 -1.383e+02 1.065e+02
## biens$`Cathédrale Notre-Dame de Paris` -2.686e+02 3.936e+02
## biens$`Basilique du Sacré-Cœur de Montmartre` 2.365e+00 4.309e+01
## biens$`Musée du Louvre` 1.044e+03 3.715e+02
## biens$`Tour Eiffel` -5.735e+01 7.395e+01
## biens$`Centre Pompidou` -8.073e+01 1.950e+02
## biens$`Musée d'Orsay` -1.870e+03 5.430e+02
## biens$`Cité des sciences et de l'industrie` 2.013e+01 3.327e+01
## biens$`Chapelle Notre-Dame de la Médaille miraculeuse` 5.701e+02 1.935e+02
## biens$`Grand site du Jardin des plantes` 1.424e+02 2.194e+02
## biens$`Arc de triomphe` 2.482e+01 7.499e+01
## biens$`Grand Palais` 4.776e+02 2.056e+02
## biens$distance_université_plus_près -1.481e+01 3.567e+01
## biens$appartement -4.702e+05 1.187e+05
## biens$studio -4.259e+05 1.438e+05
## biens$chambre -4.698e+05 1.611e+05
## biens$arrondissement 1.648e+04 6.360e+04
## t value Pr(>|t|)
## (Intercept) 1.232 0.220662
## biens$nb_chambres 0.862 0.390977
## biens$nb_photo 0.553 0.581229
## biens$surface 11.975 < 2e-16 ***
## biens$nb_pieces -1.674 0.097239 .
## biens$distance_station_0 0.082 0.935013
## biens$distance_station_1 -0.128 0.898107
## biens$distance_station_2 -1.299 0.197026
## biens$`Cathédrale Notre-Dame de Paris` -0.682 0.496566
## biens$`Basilique du Sacré-Cœur de Montmartre` 0.055 0.956341
## biens$`Musée du Louvre` 2.809 0.005970 **
## biens$`Tour Eiffel` -0.775 0.439881
## biens$`Centre Pompidou` -0.414 0.679710
## biens$`Musée d'Orsay` -3.444 0.000839 ***
## biens$`Cité des sciences et de l'industrie` 0.605 0.546473
## biens$`Chapelle Notre-Dame de la Médaille miraculeuse` 2.945 0.004012 **
## biens$`Grand site du Jardin des plantes` 0.649 0.517733
## biens$`Arc de triomphe` 0.331 0.741337
## biens$`Grand Palais` 2.323 0.022192 *
## biens$distance_université_plus_près -0.415 0.678884
## biens$appartement -3.961 0.000140 ***
## biens$studio -2.961 0.003831 **
## biens$chambre -2.917 0.004366 **
## biens$arrondissement 0.259 0.796075
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 164400 on 100 degrees of freedom
## Multiple R-squared: 0.9284, Adjusted R-squared: 0.912

```

```
## F-statistic: 56.39 on 23 and 100 DF, p-value: < 2.2e-16
```

```
# On supprime les variables qui ont une p-value très élevée
```

```
summary(lm(formula=biens$prix~biens$surface+biens$`Musée du Louvre`+biens$`Musée d'Orsay`+biens$`Chapel
```

```
##
```

```
## Call:
```

```
## lm(formula = biens$prix ~ biens$surface + biens$`Musée du Louvre` +  
##     biens$`Musée d'Orsay` + biens$`Chapelle Notre-Dame de la Médaille miraculeuse` +  
##     biens$`Grand Palais` + biens$distance_université_plus_près +  
##     biens$appartement + biens$studio + biens$chambre)
```

```
##
```

```
## Residuals:
```

```
##      Min       1Q   Median       3Q      Max  
## -709554 -52725  -2412   72177  628306
```

```
##
```

```
## Coefficients:
```

```
##                                     Estimate Std. Error  
## (Intercept)                       347234.09   164271.33  
## biens$surface                      12497.74     630.78  
## biens$`Musée du Louvre`             671.65     162.81  
## biens$`Musée d'Orsay`              -1492.87     350.73  
## biens$`Chapelle Notre-Dame de la Médaille miraculeuse`  411.62     102.94  
## biens$`Grand Palais`                415.14     104.45  
## biens$distance_université_plus_près   -38.95      17.33  
## biens$appartement                  -451472.19  105945.99  
## biens$studio                       -388622.79  128141.18  
## biens$chambre                      -427223.05  147771.50  
##                                     t value Pr(>|t|)  
## (Intercept)                        2.114 0.036714 *  
## biens$surface                      19.813 < 2e-16 ***  
## biens$`Musée du Louvre`            4.125 7.07e-05 ***  
## biens$`Musée d'Orsay`              -4.256 4.28e-05 ***  
## biens$`Chapelle Notre-Dame de la Médaille miraculeuse`  3.999 0.000113 ***  
## biens$`Grand Palais`                3.975 0.000124 ***  
## biens$distance_université_plus_près -2.248 0.026506 *  
## biens$appartement                  -4.261 4.20e-05 ***  
## biens$studio                       -3.033 0.003001 **  
## biens$chambre                      -2.891 0.004598 **
```

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
```

```
## Residual standard error: 162400 on 114 degrees of freedom
```

```
## Multiple R-squared:  0.9204, Adjusted R-squared:  0.9141
```

```
## F-statistic: 146.5 on 9 and 114 DF, p-value: < 2.2e-16
```

```
#Ensuite on ne garde que celles qui sont représentatives au seuil de 5%
```

```
summary(lm(formula=biens$prix~biens$surface+biens$`Musée du Louvre`+biens$`Musée d'Orsay`+biens$`Chapel
```

```
##
```

```
## Call:
```

```
## lm(formula = biens$prix ~ biens$surface + biens$`Musée du Louvre` +
##     biens$`Musée d'Orsay` + biens$`Chapelle Notre-Dame de la Médaille miraculeuse` +
##     biens$distance_station_2 + biens$`Grand Palais` + biens$distance_université_plus_près +
##     biens$appartement + biens$studio + biens$chambre)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -709388  -51406    3071   61789  620840
##
## Coefficients:
##                                     Estimate Std. Error
## (Intercept)                      405293.63   165923.69
## biens$surface                     12421.55     626.25
## biens$`Musée du Louvre`           677.71     161.30
## biens$`Musée d'Orsay`            -1494.48     347.41
## biens$`Chapelle Notre-Dame de la Médaille miraculeuse`  408.20     101.98
## biens$distance_station_2         -153.89      86.10
## biens$`Grand Palais`             416.80     103.46
## biens$distance_université_plus_près -35.70      17.26
## biens$appartement                -437716.14  105222.63
## biens$studio                     -383325.08  126959.98
## biens$chambre                    -417272.77  146475.28
##                                     t value Pr(>|t|)
## (Intercept)                      2.443 0.016129 *
## biens$surface                     19.835 < 2e-16 ***
## biens$`Musée du Louvre`           4.201 5.32e-05 ***
## biens$`Musée d'Orsay`            -4.302 3.62e-05 ***
## biens$`Chapelle Notre-Dame de la Médaille miraculeuse`  4.003 0.000112 ***
## biens$distance_station_2         -1.787 0.076570 .
## biens$`Grand Palais`             4.029 0.000102 ***
## biens$distance_université_plus_près -2.069 0.040856 *
## biens$appartement                -4.160 6.23e-05 ***
## biens$studio                     -3.019 0.003133 **
## biens$chambre                    -2.849 0.005216 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 160800 on 113 degrees of freedom
## Multiple R-squared:  0.9226, Adjusted R-squared:  0.9157
## F-statistic: 134.7 on 10 and 113 DF, p-value: < 2.2e-16
```

## 4 Annexes

### 4.1 Code Python

```
# Initiation de la racine du site web
site_main='https://www.pap.fr'

# Création d'un set() contenant toutes les urls des biens
URLset=GetURLSET(site_main,20)
# Nettoyage du set() pour enlever les types de biens "intéressants"
```

```

# (Fond de commerces, locaux, péniches, etc).
URLset=CleanIDset(URLset)

#Création du jeu de données brut
data=GetDetails(site_main,URLset)

#Exportation de l'objet data (dict) dans un fichier .json
exportdata(data)
# On importe les différents packages & bibliothèques
import requests
from bs4 import BeautifulSoup
from unicode import unicode
import json
import re
import datetime
import ast

# Fonction prenant en paramètre une URL et retournant l'Objet BeautifulSoup associé.
def GetHTMLPage(url_str):
    try:
        requete = requests.get(url_str,headers={'User-Agent':'Mozilla/5.0'})
        html_file = requete.content
        soup = BeautifulSoup(html_file,'html.parser')
        return soup
    except :
        print("Erreur")

#Fonction :
# paramètres : URL root + nmax : nombre page à parser.

def GetURLSET(site_main,nmax):
    res=set()
    for number in range(1,nmax+1):
        url_str=site_main+'/annonce/vente-immobiliere-paris-75-g439-'+str(number)
        soup=GetHTMLPage(url_str)
        temp=GetSet_URL_Bien(soup)
        res=res|temp
    return res

def GetSet_URL_Bien(soup):
    liste_hrefs=set()
    spans_bien=soup.find_all('div',class_="search-list-item")
    for item in spans_bien:
        str_href=item.find('a').get('href')
        liste_hrefs.add(str_href)
    return liste_hrefs

#Fonction de filtre
def condition_keep(string):
    substring_list = ("/annonces/appartement-paris","/annonces/maison-paris")
    if (string.startswith(substring_list)):

```

```

        return True
    else:
        return False
#Fonction de nettoyage de URLset.
def CleanIDset(URLset):
    keep_set=set()
    for item in URLset:
        if(condition_keep(item)):
            keep_set.add(item)
    return keep_set

#Fonction de scrapping des informations pour un bien immobilier particulier
def GetDetails(site_main,URLset):
    res=[]
    for url_detail in URLset:
        url_str=site_main+url_detail
        soup_ID = GetHTMLPage(url_str)
        to_append=ScrapDetail(soup_ID)
        to_append['url']=url_detail;
        res.append(to_append)
    return res

def Cleandataset(data):
    keys=['.', 'EUR le m']
    for key in keys:
        if key in data.keys():
            del data[key]
        else :continue
    return data

def GetDetailsBien(div_desc,res):
    patterns= [r'\D+']

    list_item_tag=div_desc.find(class_='item-tags')
    list_item_tag=[unicode(item.strong.text) for item in list_item_tag.find_all('li')]
    for item in list_item_tag:
        for p in patterns:
            matches= re.findall(p, item)
            for match in matches:
                res[unicode(match).strip()]=format_list_tag(item)
    res=Cleandataset(res)

    return res

def format_list_tag(item):
    item=re.sub('m2', '', item)
    item=re.sub('[^\d]', '', item)
    return int(item)

def ScrapDetail(soup):

```

```

res={}
type_bien=soup.find(class_='item-title').text
res['type']=type_bien.split()[1]
nb_photo=len(soup.find_all(class_='img-liquid owl-thumb-item'))
res['nb_photo']=nb_photo

div_desc=soup.find('div',class_="item-description")
# Collecte du prix du bien
tarif=soup.find(class_='item-price').text
tarif=re.sub('[^\d]', '', tarif)
res['prix']=tarif

# Collecte du code postal
zipcode=div_desc.find('h2').text
zipcode= re.findall(r"(\b\d{5}\b)", zipcode)[0]
res['code postal']=zipcode
## Collecte des Stations de métro
list_station=div_desc.find_all(class_='item-transports')

list_name_station=[]
for item in list_station :
    to_append=item.find(class_='label')
    if(type(to_append)!=type(None)):
        list_name_station.append(to_append.text)

res['transport']=list_name_station

## Collecte des détails
GetDetailsBien(div_desc,res)
## Collecte des coordonnées
GetCoord(soup,res)
return res

def GetCoord(soup,res):
# print(carte_item)
carte_item=ast.literal_eval(carte_item['data-mappy'])
res['lat']=float(carte_item['center'][0])
res['lon']=float(carte_item['center'][1])
return res

#Fonction d'exportation du dictionnaire : dict_data
def exportdata(dict_data):
    x = datetime.datetime.now()
    x=x.strftime("%H-%M-%S")
    with open('result-'+x+'.json', 'w') as fp:
        json.dump(dict_data, fp)
    return x

```

## Références

« Coordonnées GPS ». 2020. Coordonnées GPS. <https://www.coordonnees-gps.fr/>.



- « Monuments de Paris ». 2020. Monuments de Paris. <http://www.quotidiendutourisme.com/france/quels-sont-les-monuments-les-plus-visites-de-paris/170372>.
- « PAP: Particulier à Particulier ». 2020. Entreprise de presse immobilier français. <https://pap.fr>.
- « RATP Open Data ». 2020. Régie autonome des transports parisiens. [https://dataratp2.opendatasoft.com/explore/dataset/positions-geographiques-des-stations-du-reseau-ratp/table/?disjunctive.stop\\_name](https://dataratp2.opendatasoft.com/explore/dataset/positions-geographiques-des-stations-du-reseau-ratp/table/?disjunctive.stop_name).
- « Université de Paris ». 2020. Université de Paris. <https://www.sorbonne.fr/toutes-les-universites/>.